Relatório Lab 11 - CT213

Código: A implementação do código foi bem direta, os métodos epsilon_greedy_action e learn (dos dois algorimos) foram o foco da parte não implementada. O primeiro método foi obtido utilizando a função choice da biblioteca random do numpy, onde passamos como argumento as escolhas possíveis e a probabilidade de cada uma delas. Ambos métodos learn foram baseados nas equações de Bellman (expectativa no Sarsa e otimalidade no Q-Learning).

Resultados: Podemos observar que nas 100 primeiras interações ambos algoritmos exploram (o Sarsa explora fortemente apenas no começo). Ambos algortimos convergem rapidamente para uma política capaz de concluir o trajeto (vide caminho percorrido com 20 interações)

Q-Learning: Return:

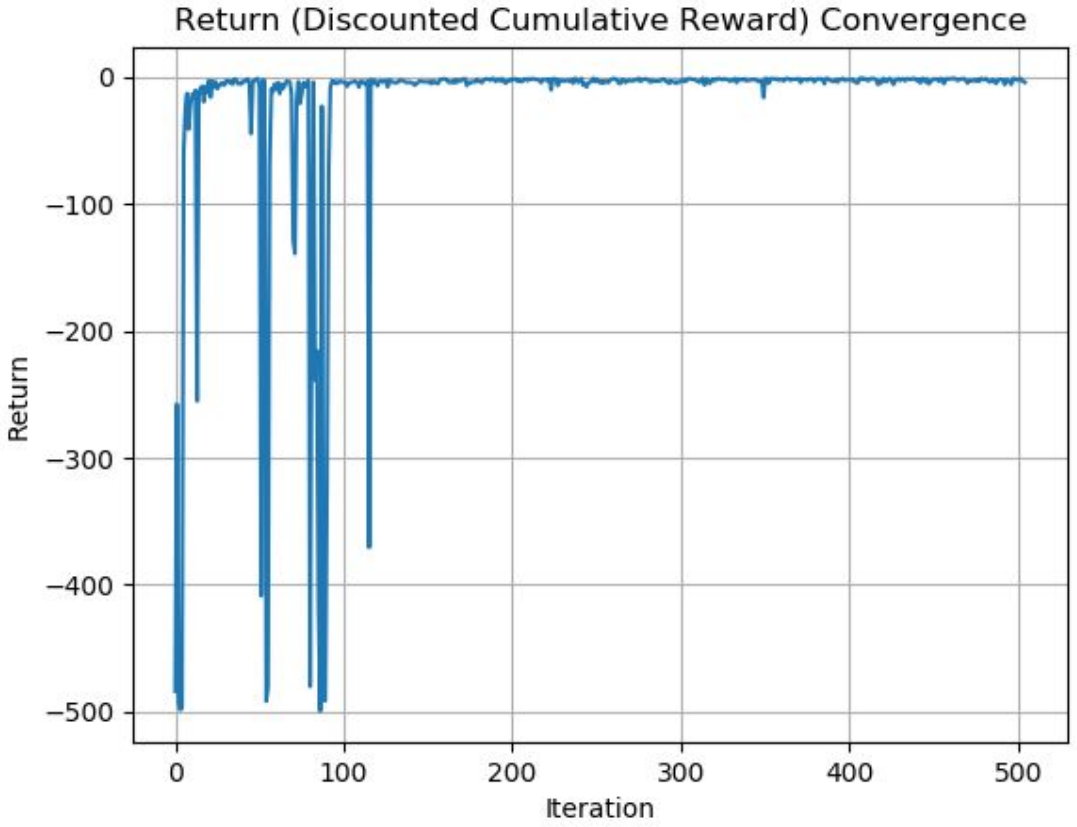

Q-Learning Q Table:

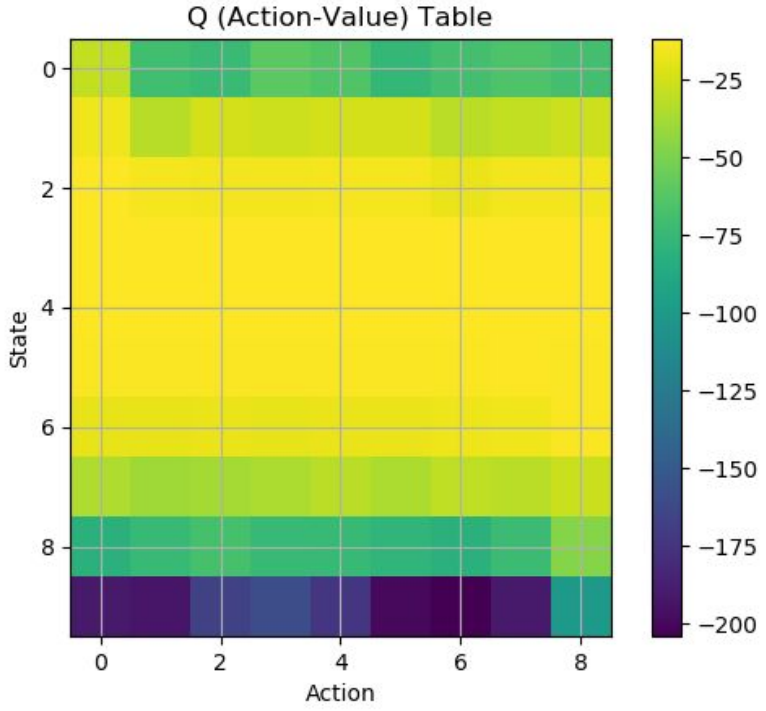

Q-Learning Greedy Policy Table

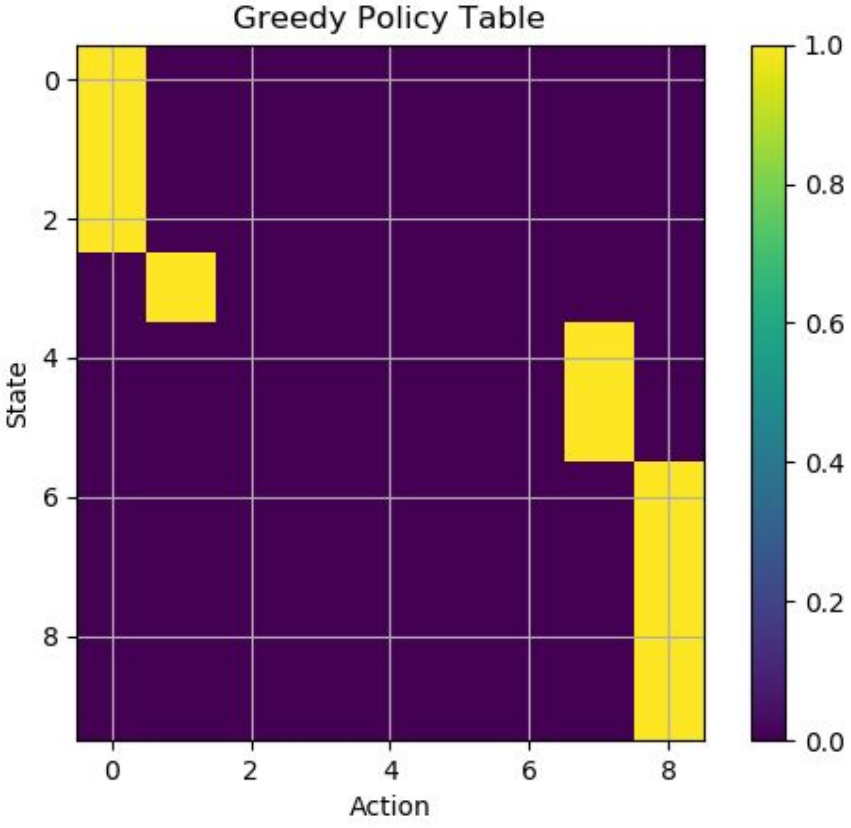

Q-Learning 505 interações:

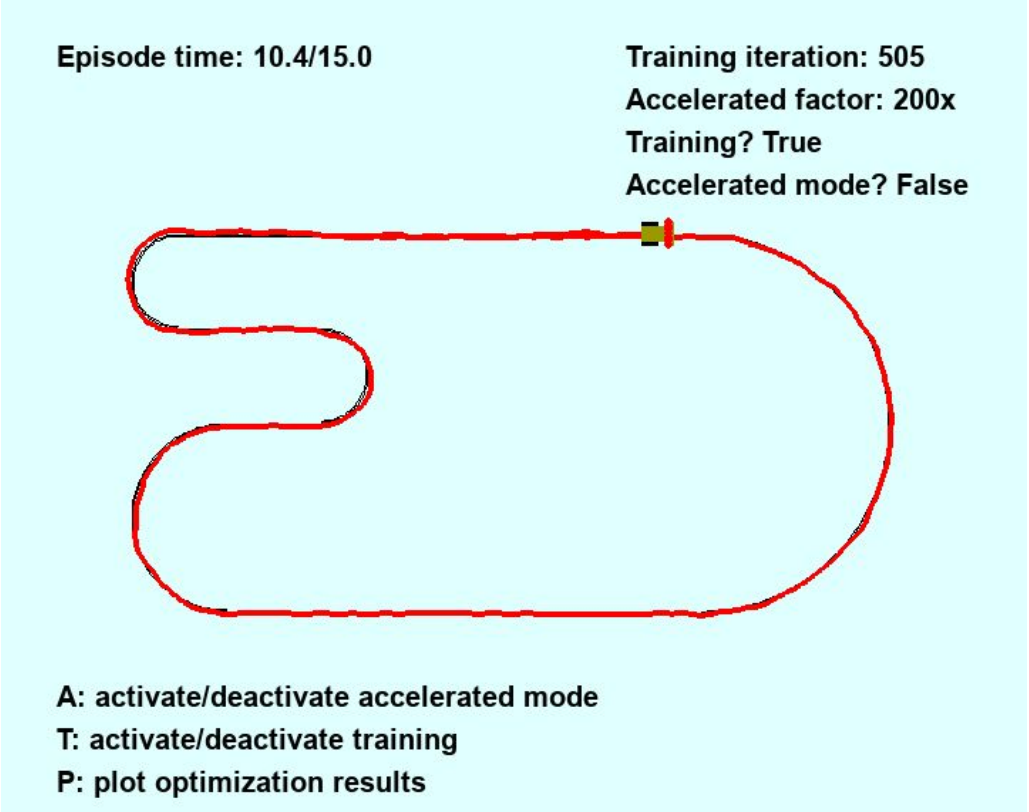

Q-Learning 21 interações:

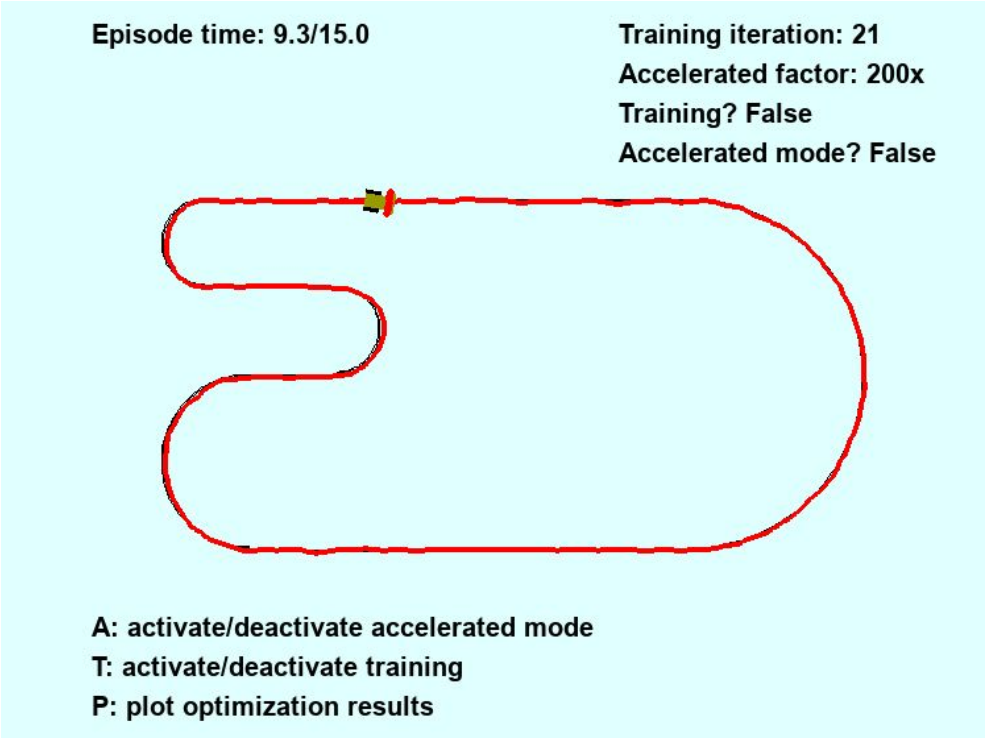

Sarsa - Return Convergence:

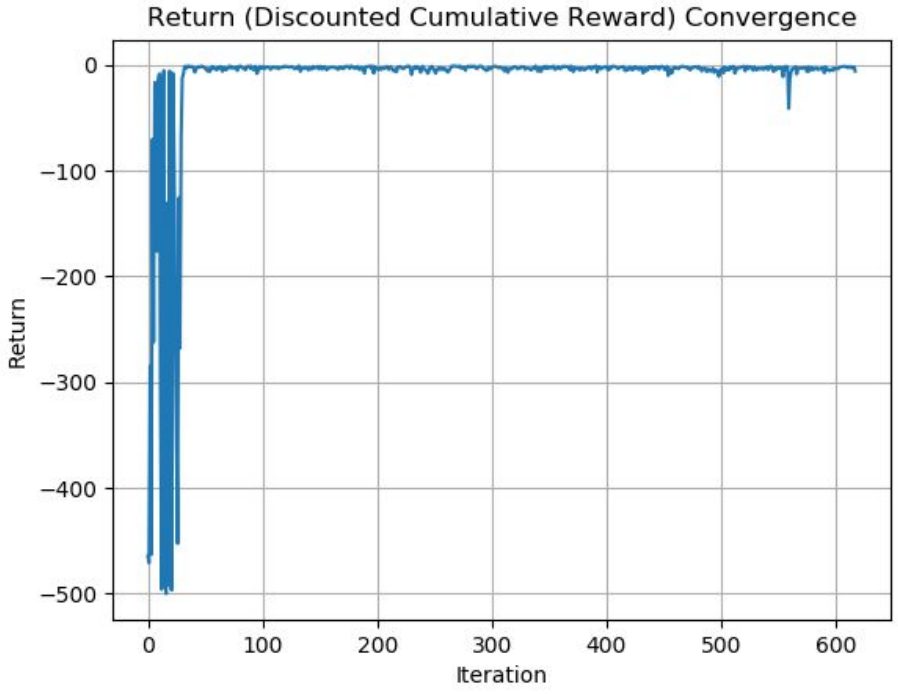

Sarsa - Q Table:

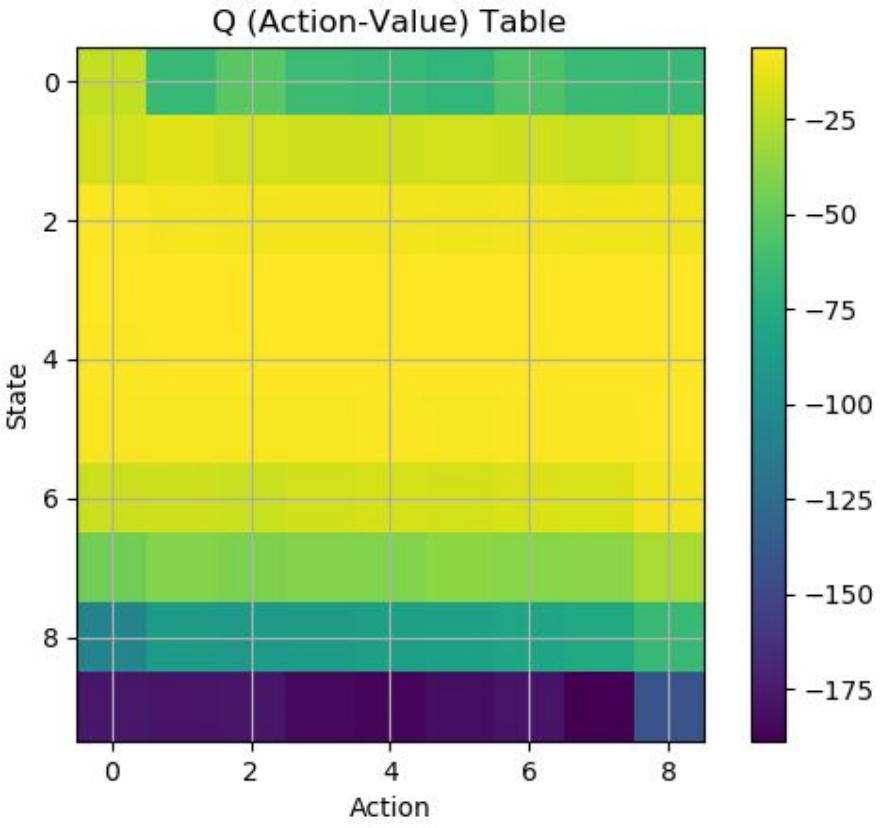

Sarsa - Greedy Policy Table

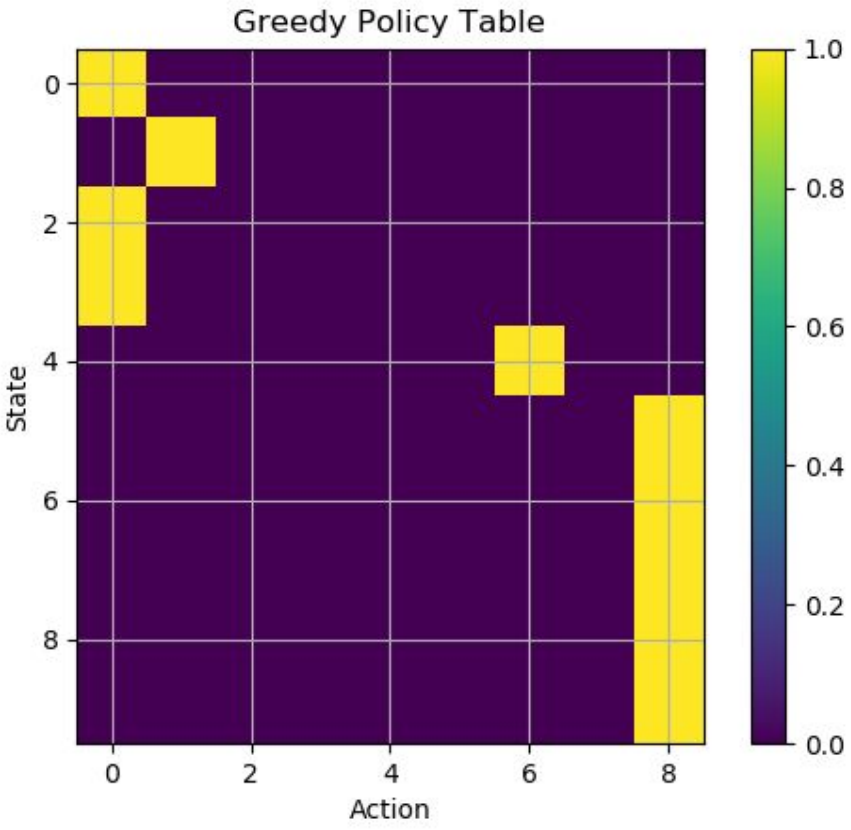

Sarsa 600 interações:

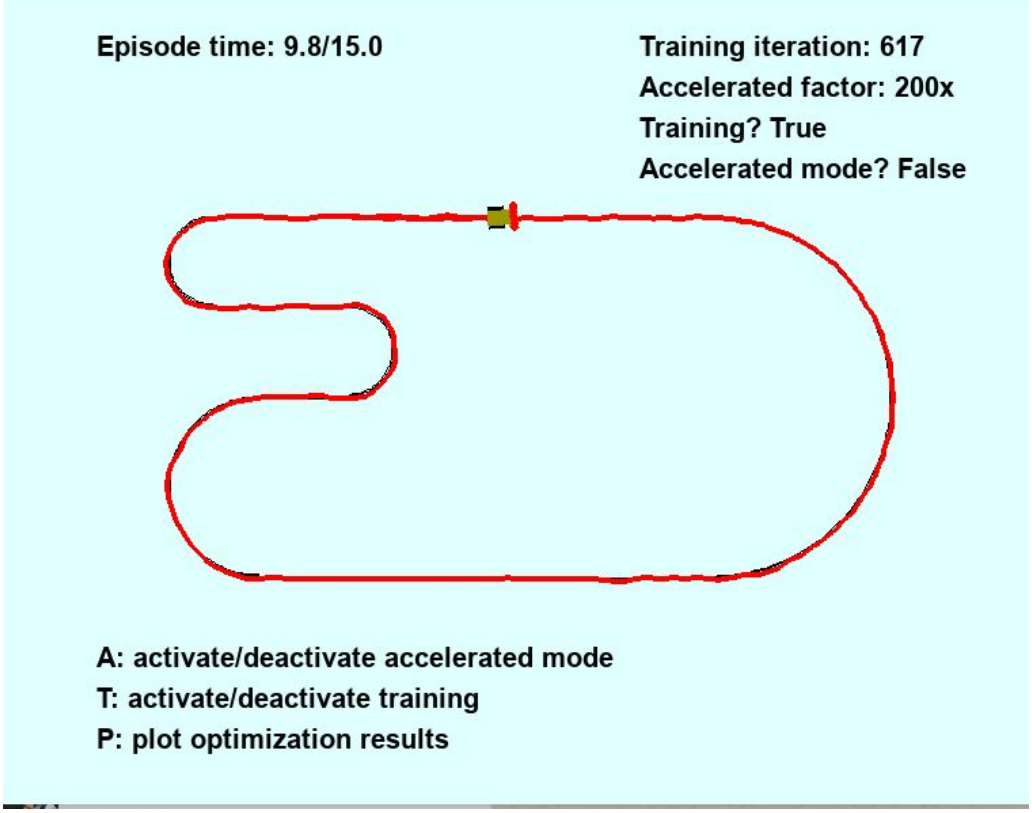

Sarsa 20 Interaçôes: